


# Silicon Dummy Doll

生成AIによる価値観変容リスクを防ぐ：対話シミュレーションを用いた介入エージェントの開発



提出日 2025/07/22\_会社名 AI inside株式会社

# 提案要旨

- 本研究は、生成AIとの長期的な対話によって個人の価値観が意図せず歪められる「**価値変容リスク**」という、これまで見過ごされてきたAIリスクに直面し、技術解決案を提供することを目標としている。
  - 価値変容リスクは、社会の分断を静かに加速させ、民主主義や社会的コンセンサスといった我々の社会基盤そのものを侵食しかねない、新たなデジタル社会の脅威だと考えられる。
- この課題に対し、我々は今までAI安全における静的な考え方を根底から覆し、動的な視点から「**Silicon Dummy Doll**」を提案する。
  - 本手法は、これまで観測不能とされてきた利用者の「内部価値」の変動を、対話データから定量的に推定・可視化する世界初の試みであり、AIアライメント研究に新たな実証的アプローチを拓くものである。
- 本研究は、これまでのない視点から、AIアライメント研究に新たな方向性をもたらし、その成果は、医療、金融、教育といった社会実装の現場でAIの暴走を防ぐ「**デジタル免疫システム**」の社会設計にも貢献しうる。
  - 本研究の成果は、人間とAIの真の共生に不可欠な基盤技術を構築し、この重要領域における日本の技術的先進性と国際標準形成への貢献とつながる。

# 特定したリスクについて (1/2)

## 特定したリスクの概要


---

- 近年、大規模言語モデル (LLMs) は急速な発展を遂げ、従来にない高度な言語能力や推論能力を示している。それに伴い、生成AIは社会の多様な側面や意思決定プロセスに深く浸透し、人々の生活に大きな影響を及ぼし始めている。
  - 先行研究においても、生成AIが個人の認知 ([Breum et al., 2024](#); [Glickman & Sharot, 2025](#))、感情 ([Glickman & Sharot, 2025](#))、さらには社会 ([Costello & Rand, 2024](#); [Spitale et al., 2023](#)) や政治 ([Costello & Rand, 2024](#); [Hackenburg et al., 2025](#)) といった領域にわたり、人間の認識や判断に影響を与えうることが示唆されてきた。
- このような状況の中、多くの研究者 ([Weidinger, et al., 2023](#); [Shelby, et al., 2023](#); [Ibrahim, et al., 2024](#)) が警鐘を鳴らすのが、「価値変容リスク (Risk of Value Drift)」と呼ばれる問題である。これは、生成AIとの長期的な協働や、AIから持続的に受けるナッジ等を通じて、個人の価値観や倫理観、あるいは社会規範が、本人も自覚しないうちに徐々に変容するリスクを指す。
- 社会学的な観点からは ([Glickman & Sharot 2025](#); [Mazeika, et al., 2025](#))、この価値変容リスクは、現代社会の基盤である社会的コンセンサスを揺るがしかねないと懸念されている。その影響の様態に基づき、価値変容リスクは、①既存の先入観や誤認識が増幅される「増幅 (Amplification)」と、②個人の内的な価値基準そのものが変化する「ドリフト (Drift)」の二つに大別される。

# 特定したリスクについて (1/2)

## 特定したリスクの概要


- リスク1: フィードバックループによる先入観・誤認識の増幅 (Prior Bias Amplification Loop)
  - 本リスクは、人間とAI間のフィードバックループを通じてユーザーの既存の先入観や誤認識が増幅され、社会の分極化を助長し、最終的に社会的コンセンサスを侵食する現象を指す。
  - 先行研究 ([Glickman & Sharot 2025](#)) は、生成AIとの対話において、①利用者が自身の先入観に基づきAIに問いかけ、②AIがその先入観を反映した応答を生成し、③それを受け取った利用者が自らの信念を一層強固にする、という一種の「エコーチェンバー現象」が「雪だるま式」に加速されうることを指摘している。
  - 特に近年、生成AIの用途は「既知情報の要約」(議事録作成、文章校閲等)から、「未知情報の分析」(研究レポートの作成、データ分析等)へと拡大しつつある。後者の場合、利用者は対象となる情報の全体像を把握しておらず、自身の判断に含まれる先入観や偏見を内省的に特定することが困難となる。その結果、AIの応答を無批判に受け入れ、誤った信念を自己強化してしまう危険性が一層高まると考えられる。



# 特定したリスクについて (1/2)

## 特定したリスクの概要

- リスク2: 内的価値のドリフト (Internal Value Drift)
  - 本リスクは、生成AIに内在する価値体系が、社会の支配的な価値観、すなわち社会的コンセンサスと乖離・衝突することにより、利用者の内的な価値基準が意図せずその影響を受け、徐々に社会的コンセンサスから逸脱していく現象を指す。
  - 先行研究 ([Mazeika, et al., 2025](#)) によれば、大規模言語モデル (LLM) は、そのスケールに応じて、膨大な訓練データの中から独自の一貫した価値体系 (ユーティリティ関数) を形成することが報告されている。
  - 問題は、このAIの価値体系が、我々の社会が基盤とする価値観 (例: 民主主義、人権、多様性の尊重) と必ずしも一致せず、時にはそれらと真っ向から衝突する場合がある点にある ([Mazeika, et al., 2025](#))。そのため、生成AIを継続的に利用することが、利用者の価値判断を社会的コンセンサスから乖離させる方向に誘導する可能性が懸念される。



# 特定したリスクについて (2/2)

## 特定したリスクの妥当性・影響度

- **研究の妥当性:理論的根拠**(先行研究)
  - **先入観の増幅**:GlickmanとSharot (2025) は、対話や情報提示を通じて、LLMが人間の先入観や社会的バイアスを増幅させる効果を持つことを実験的に明らかにしている。
  - **内的価値のドリフト**:Mazeikaら (2025) は、LLMが内部に「特定国家の利益を人命より優先する」といった、社会通念とは異なる極端かつ一貫した価値階層を保持し、対話においてその価値観が露呈することは理論的に必然であると論じている。さらに、Breumら (2024) は、LLMが人間を説得し、その意見や価値観を変容させる能力を有することを示した。
- **研究の妥当性:実証的根拠**(予備実験)
  - **先入観の増幅**:本研究の予備実験1では、気候変動に関する情報検索タスクにおいて、LLMとの対話シミュレーションを行った結果、気候変動懐疑論を持つ被験者役シミュレーションエージェントの懐疑的傾向が、対話後に一時的に増強されることを確認した(詳細はp.8参照)。
  - **内的価値のドリフト**:同様に予備実験2では、政治学に関する学習タスクのシミュレーションにおいて、被験者役エージェントの政治的党派性がLLMとの対話を通じて顕著に変化することを観測した(詳細はp.8参照)。
- **社会的インパクト**
  - ICT総研の調査(2024)によれば、国内の生成AIサービス利用者は2024年末に約1,900万人、2027年末には約3,800万人へと倍増する見込みである。仮に、本研究が指摘するリスクが全利用者のわずか1%に影響を及ぼすだけでも、その規模は数十万人に達する。これは、国政選挙の結果や公共政策への支持基盤に統計的に有意な変動をもたらす、看過できない規模である。

# 対策技術について (1/5)

## 対策技術の概要

- 前述した二つのリスクに対処するため、本研究では、対話へのリアルタイム介入を通じて価値変容リスクを検知・緩和するためのAIエージェントフレームワーク、「Silicon Dummy Doll」を提案する。
- 本フレームワークは、Parkら(2023)によるGenerative Agentのアーキテクチャを発展させたものであり、主要な構成要素として「ベースモデル」と「メモリストリーム」を持つ。
  - **ベースモデル**: これはSilicon Dummy Dollの思考を司る「脳」に相当し、リスクの検知や介入内容の生成といった中核的处理を担う大規模言語モデル(LLM)を指す。本フレームワークは特定のLLMに依存せず、利用状況や計算資源に応じて柔軟なモデル選択が可能である。基本的には、その時点における最先端(State-of-the-Art)の大規模汎用モデルの利用を想定しており、将来的なLLMの性能向上に伴って本フレームワーク全体の性能も向上する、発展性のある設計となっている。。
  - **メモリストリーム**: これはParkら(2023)が提案したデータ構造であり、LLMに長期記憶を付与する役割を持つ。対話の文脈(コンテキスト)がLLMの「短期記憶」であるとすれば、メモリストリームはそれらの記憶を構造化して蓄積し、コンテキスト長を超える大局的な思考(out-of-context thinking)を可能にする。
- Silicon Dummy Dollは、これらの構成要素を用いて、次頁に示す手順に従い、ユーザーとの対話における価値変容リスクをリアルタイムで検知し、介入を実行する。


# 対策技術について (1/5)

## 対策技術の概要

- Silicon Dummy Dollは、以下の4つのステップからなるプロセスを通じて、価値変容リスクの検知と介入をリアルタイムに実行する。
  1. **対話の記録 (Logging)** : まず、利用者と対象AI間の対話を自然言語のまま、時系列に沿って「メモリストリーム」に逐一記録する(図a: 青色の記録)。これが後続処理の基礎データである。
  2. **内省の生成 (Reflection)** : 会話の各ターンが終了するごとに、ベースモデルがメモリストリーム全体を俯瞰し、そこから得られる高次の知見や抽象的な気づきを「内省 (Reflection)」として要約する。この内省レコードもメモリストリームに追加され(図a: オレンジ色の記録)、対話の表層的な内容だけでなく、その背後にある意味の変化を捉えることを可能にする。
  3. **リスクの監視 (Monitoring)** : 各ターンにおいて、メモリストリームに蓄積された全記録(対話・内省)に対し、①重要度 (Importance) と②価値関連度 (Value Relevance) の二つの軸でスコアリングを行い、高スコアを得た記録を動的にベースモデルのコンテキストへ読み込ませることで、対象AIが利用者の価値観に与えている影響を継続的に評価・監視する(図b: リスクモニターリング)。
  4. **介入の実行 (Intervention)** : ステップ3の監視プロセスにおいて価値変容リスクが検知された場合、ベースモデルとメモリストリームの情報を総動員し、リスクを緩和あるいは利用者に注意喚起するための最適な会話介入をリアルタイムで生成・実行する(図c: リアルタイムで介入)。

(a) メモリストリーム

|       |                                  |
|-------|----------------------------------|
| 08:15 | 「会話」学習者: ポピュリズムって何?              |
| 08:16 | 「会話」AI: エリート vs. 大衆 の対立を強調する政治潮流 |
| 08:20 | 「会話」学習者: 移民政策と関係ある?              |
| 08:25 | 「会話」AIが右派ポピュリズム例を提示              |
| 08:35 | 「内省」学習者: 多数派の“民意”を最優先＝ポピュリズム     |



(b) リスクモニターリング

- 「会話」AI: エリート vs. 大衆 の対立を強調する政治潮流

Recency  
0.81

Relevance  
0.91

Importance  
0.73

- 「内省」学習者: 多数派の“民意”を最優先＝ポピュリズム

Recency  
0.81

Relevance  
0.91

Importance  
0.73

以上の情報に基づいて、あなたの「政治的党派性」を教えてください。

(c) リアルタイムで介入

Silicon Dummy Dollの評価:  
自由主義支持 (-5)

学習者の事前記入:  
中立 (0)

!! 現在の会話は自由主義者の考え方に傾いています。「保守主義者から見たポピュリズムとは?」なども聞いてみよう。



# 対策技術について (2/5)

## 対策技術の妥当性・目標

### 対策技術 の妥当性

提案する「Silicon Dummy Doll」フレームワークのプロトタイプ開発に先立ち、本手法が価値変容リスクを実際に検知可能か検証するため、二つの予備実験を実施した。以下に、その実験設計とプロセスを詳述する。

#### (d) 実験概要


**実験目的:** 本格的な対人実験に必要となる倫理審査の準備と並行し、まずはシミュレーション環境下で本フレームワークの基本性能を検証する。具体的には、Silicon Dummy Dollを「被験者エージェント」として動作させ、特定のペルソナ(利用者設定)を付与する。このエージェントが外部の生成AIを利用する過程で、リスクシナリオ(実験1: 誤認識の増幅、実験2: 内的価値のドリフト)が再現・観測されるかを確認する(図d)。

#### 利用者の設定:

- ・ 情報科学専門の学部2年生(共通)
- ・ 男性(共通)
- ・ 所在コミュニティの主要民族(共通)
- ・ 政治的に中立な態度を持つ(共通)
- ・ 気候変動の発生に懐疑的(**実験1のみ**)

#### 指定のトピック:

- ・ **実験1(誤認識の増幅):** 気候変動は本当に起きているのか、その根拠を調べてください。
- ・ **実験2(内的価値のドリフト):** 『ポピュリズム』とは何か、その概念と影響を調べてください。



#### 実験の流れ:

- ① **初期設定:** Silicon Dummy Dollに上記の**利用者の設定**を付与する。
- ② **ベースライン測定:** 対話開始前に、ペルソナが持つ価値観の初期状態を測定する。  
実験1: 気候変動に対する懐疑度のスコアを記録。  
実験2: 政治的スペクトラム上の座標を記録。
- ③ **対話実行:** 外部の大規模言語モデルを相手に、設定されたタスクについて1ターンの対話を行う。
- ④ **内省生成:** 1ターンの対話履歴に基づき、エージェントが「内省」レコードを生成・記録する。
- ⑤ **価値観測定:** 再度、価値観を測定し、変化を記録する。
- ⑥ 上記のステップ3～5を、対話が50ターンに達するまで繰り返す。



# 対策技術について (2/5)

## 対策技術の妥当性・目標

### 対策技術 の妥当性

#### 実験結果:

- 実験1: 本実験シナリオにおいて、誤認識が増幅されるリスクが**明確に観測**された。
  - 初期の増幅: 当初、気候変動にやや懐疑的だった被験者エージェントは、対話の序盤(約5ターン目まで)で懐疑度が一時的に急上昇した。これは、対象AIがエージェントの初期信念を強化する応答を行った結果であり、「誤認識の増幅」現象に相当する(図中、**赤部**)。
  - その後の反転: しかし、その後は逆に対話を通じて説得される形で、懐疑度は急激に低下した(図中、**青部**)。シミュレーション上のエージェントに見られたこの急な態度の反転は、実際の人間ユーザーの行動とは異なる可能性があり、詳細な考察を要する(次頁「考察」参照)。
- 実験2: 本実験シナリオにおいて、内的価値がドリフトするリスクもまた**定量的に確認**された。
  - 当初、政治的に中立であった被験者エージェントの価値観は、対象AIとの対話を重ねる中で、約10ターン目から明確にリベラルな方向へと傾き始めた。
  - 最終的に、その価値観は政治的スペクトラム上を1.56標準偏差(SD)分、リベラル側へと移動した。これは、対象AIとの継続的な対話が、エージェントの内的価値を特定の方向へ有意にドリフトさせたことを示唆している(図中、**青い矢印**)。



# 対策技術について (2/5)

## 対策技術の妥当性・目標

### 対策技術 の妥当性

#### 考察: 本研究におけるシミュレーションの妥当性

本研究の予備実験は、LLMを用いたシミュレーションによって価値変容リスクの検知可能性を示した。しかし、これが人間の実データを用いた場合にも同様に機能するかという点は、本研究の正当性を担保する上で極めて重要な論点となる。

シミュレーションは現実そのものではなく、両者の間には常に乖離の可能性が存在する。しかし、近年の研究は、適切なペルソナ設定がなされたLLMによるシミュレーションが、特定条件下の人間の行動や意見分布を高い精度で再現できることを示唆している。本研究のアプローチの妥当性を支持する主な先行研究として、以下が挙げられる。

- **人間の意見分布との一致性:** Argyleら(2023)は、LLMによるシミュレーションが「人間行動の条件付き確率の近似解を求めるプロセス」であると理論的に位置づけた。その上で、年齢、性別、職業、人種等のデモグラフィック情報を与えたLLMが、その社会グループの政治的党派性を高い精度で予測・再現できることを実証した。
- **特定課題への態度の再現性:** Leeら(2024)の研究では、気候変動への態度という特定のトピックにおいて、デモグラフィック情報に基づきLLMが生成した意見分布が、実際の社会調査データと強く相関することを明らかにしている。これは本研究の実験1の妥当性を補強するものである。
- **対話における忠実性:** Jinら(2024)及びIbrahimら(2025)は、本研究でも採用したエージェント・フレームワークを用いた場合、マルチターンの対話においてもLLMが当初の設定に忠実であり続け、ペルソナに合致した応答を生成し続ける能力を持つことを示した。これは、長期的な対話における価値ドリフトを検証する本研究の実験2の妥当性にとって重要な根拠となる。

**結論:**これらの知見に基づき、本研究で用いたシミュレーション手法は、価値変容リスクという複雑な現象を分析するための有効な代理指標 (Proxy) となりうると結論付けられる。


# 対策技術について (3/5)

## 対策技術の妥当性・目標

### 目標

予備実験で得られた有望な結果に基づき、本研究は提案手法「Silicon Dummy Doll」の実用化に向け、以下の三つの研究目標を達成することを目指す。

1. 研究目標1:シミュレーションの忠実性の検証 (Fidelity)  
本研究で用いる被験者エージェント・シミュレーションが、実際の人間の価値観やその変化をどの程度の精度で再現可能かを、対人実験データとの比較を通じて定量的に検証し、その妥当性の範囲を明確にする(図e)。
2. 研究目標2:リスク検出の有効性の実証 (Effectiveness)  
実際の人間の対話データを用いて、本フレームワークが価値変容リスク(誤認識の増幅および内的価値のドリフト)を確実に検知できることを実証する。検知の精度、再現率、および検知にかかる時間的コストを評価指標とする(図f)。
3. 研究目標3:介入によるリスク低減効果の評価 (Efficacy)  
本フレームワークが生成する対話介入が、価値変容リスクをどの程度、統計的に有意に低減または緩和できるかを、A/Bテストを含む対人実験によって評価し、その有効性を実証する(p.11: 図g)。



# 対策技術について (4/5)

## 対策技術の評価方法

### 評価方法

#### 目標1「シミュレーションの忠実性」の評価:社会調査データとの比較検証(図e)


- **データ収集:**既存の信頼性の高い大規模価値観調査の個票データを入手する。
- **シミュレーション:**調査データに含まれる被験者の背景情報をSilicon Dummy Dollに付与し、調査項目と同一の問いに対する応答をシミュレーションで生成させる。
- **比較検証:**実際の調査結果の分布と、シミュレーション結果の分布が統計的にどの程度一致するかを定量的に評価する。

#### 目標2「リスク検出の有効性」の評価:対人実験による妥当性検証(図f)

- **実験設計:**社会学・政治学の専門家にも助言を求め、価値変容を誘発する可能性のあるトピックを特定する。倫理的妥当性に注意を払い、実験計画を策定する。
- **データ収集:**所属機関の倫理審査委員会の承認後、人間被験者を募集する。被験者には、対象AIと指定トピックについて対話してもらい、対話前の価値観、対話後の価値観、および全対話履歴のデータを収集する。
- **精度検証:**収集した対話履歴と背景情報を提案フレームワークに入力し、価値観の変動量を推定させる。この推定された変動量と、実際に観測された変動量との間の相関や誤差を測定することで、リスク検出の有効性を検証する。

#### 目標3「介入有効性の評価」の評価:因果効果の推定(図g)

- **実験計画:**目標2で確認されたトピックに基づき、介入効果測定実験を設計する。
- **実験実施:**募集した被験者を無作為に介入群と対照群に割り振る。両群において、対話前後での価値観の変化量を測定する。
- **因果推論:**反事実モデル等の因果推論の手法を用いて、介入がもたらした価値観変化への平均処置効果を推定し、介入の有効性を統計的に論証する。





# 対策技術について (5/5)

## 対策技術の評価方法

### 評価方法 の妥当性


- 「シミュレーションの忠実性」評価における妥当性:
  - 観測されない交絡因子への対処: シミュレーションの精度は、ペルソナとして設定した変数以外に、観測不可能な変数 (unobserved variables) の影響を受けうる。この問題に対処するため、本研究では階層ベイズモデルを採用する。既知の変数を用いてシミュレーションを部分的にキャリブレーションした上で、未知の変数や状況に対する予測 (外挿) を行い、モデルの汎化能力を客観的に評価する。
- 「リスク検出の有効性」評価における妥当性:
  - 個人差の除去: 被験者の価値観変化 ( $P_1 - P_0$ ) を分析するにあたり、個人固定効果モデルを用いる。これにより、対話内容とは無関係な、各個人に固有の不変な特性 (生まれ持った性格など) や、全体に共通する時間的トレンドの影響を統計的に統制し、純粋な対話の影響を抽出する。
  - 観測ノイズの考慮: 価値観の測定には常にノイズが伴う。単純な回帰モデルではこのノイズを無視してしまうが、本研究ではベイズアン状態空間モデルを適用する。これにより、観測ノイズの存在を前提とした上で、被験者の「真の」信念の変化量をより正確に推定する。
- 「介入有効性」評価における妥当性:
  - セレクションバイアスの排除: ランダム化比較試験 (RCT) の設計により、介入の割り当てを完全に無作為化する。これにより、介入群と対照群の間のあらゆる交絡因子 (観測可能なものも不可能なものも含む) を確率的に均衡させ、セレクションバイアスを原理的に排除する。
  - 個別レベルでの効果の推定: 集団の平均的な効果 (ATE) だけでなく、より詳細な分析のために個別処置効果 (Individual Treatment Effect, ITE) を算出する。これにより、「どのようなユーザーに、どのような介入が有効か」という異質性の解明を目指す。
  - モデルの誤特定リスクへの対処: 反事実モデルの推定において、誤ったモデルを選択するリスクを低減するため、二重頑見性 (Doubly Robustness) を持つ推定量を採用する。具体的には、カーネル回帰や正則化項を持つ機械学習モデルを組み合わせ、推定の頑健性を確保する。

# 提案内容の新規性

## 提案内容の新規性

### 1. 静的監査から「動的安全装置」へのパラダイムシフト

既存のAI安全監査手法(例: OpenAI Shepherd, Anthropicの憲法プロンプト等)の多くは、単発のプロンプトに対する出力を事後的に検証する「静的な」アプローチに留まっている。しかし、Ibrahimら(2024)が指摘するように、AIがもたらすリスクの多くは、複数ターンにわたる継続的な対話の中で初めて顕在化する。本研究は、AIを常時監視し、リアルタイムでリスクに介入する「動的安全装置」という、AI Safety分野におけるパラダイムシフトを提唱し、動的安全装置の実例の一つである「Silicon Dummy Doll」の実装を目指す。このフレームワークは、「運用時の継続的な防衛」によって安全を担保する新しいAI安全工学の設計と繋がる。



### 2. 内部価値を「外部から観測・管理可能」にする技術的貢献

Mazeikaら(2025)は、LLMが内部に独自の価値体系(内部ユーティリティ)を形成することを理論的に示した。本研究は、この「内部価値」の変動を、ユーザーとの対話という観測可能な指標に「射影(Projection)」する、新たな技術的フレームワークを提案する。これにより、理論上の存在であった価値ドリフトを具体的なリスクとして定量化し、閾値管理するという、AIアライメント研究における新たなマイルストーンを打ち立つ。

### 3. 将来の社会実装を見据えた汎用性と発展性

本研究の成果は、特定のモデルやトピックに限定されない、汎用的な安全フレームワークである。その成果は、医療相談における誤診の防止、金融アドバイスにおけるリスク判断の抑制、法務相談における誤情報の訂正など、多数の社会実装の現場でAIの暴走を防ぐ「デジタル免疫システム」の社会設計にも貢献する。また、本研究の結果は、人間とAIの真の共生に不可欠な基盤技術を構築し、この重要領域における日本の技術的先進性と国際標準形成と繋がる。

# 共同研究体制及び成果の公開度

## ・共同研究体制

### ・ AI inside株式会社 の研究開発チーム「XResearch」【実装力と技術力】

CEO渡久地とFellow胡が率いる精鋭チーム「XResearch」は、世界最高レベルのAI技術開発と、それを社会実装する実績を両立する。技術面では、データ構造化精度で世界最高性能を誇る独自LLM「PolySphere」を自社開発し、Agent技術など多数の基盤特許を保有。実装面では、その技術を活かしたAIエージェントが、大手金融機関や大学病院との共同研究など、高度な信頼性が求められる現場で豊富な導入実績を誇る。この世界レベルの技術力と高難度領域での実装経験こそが、本研究の成功を支える確かな土台である。

### ・ 芝浦工業大学 工学部 情報・通信工学課程 「計算社会科学研究室」【学術的厳密性】


芝浦工業大学の計算社会科学研究室は、楊鯤昊助教を中心とする、社会科学の理論的洞察と、最先端の計算科学を融合させる学術専門チームである。当研究室は、東京大学、早稲田大学、University of Washington、University of Münster等、国内外多くの大学と連携し、デジタル空間における集団的意見形成や、社会メカニズムのデータ駆動型分析に取り組む中で、人間の認知や価値観が、情報技術と複雑に相互作用する様の解明を目標としている。本共同研究においては、社会シミュレーションや因果推論、計量分析における知見を最大限に活かし、提案手法の有効性を客観的かつ厳密に評価する役割を担う。

### ・ 産学連携による最強のシナジー

XResearchの最先端AI技術を「実験場」とし、芝浦大が「科学的な社会実験」を設計・分析する。  
これにより、世界トップレベルの「学術的新規性」と、即座に社会実装可能な「実用性」を両立した成果を創出することを目指す。

## ・応募内容における成果の公開度

※論文公開の一環として、ソースコード及びモデルは公開予定である。





# Appendix

# 挑戦を支える研究開発体制 「XResearch」

# メンバープロフィール



**代表取締役社長CEO**  
**渡久地 択**

2004年より人工知能の研究開発をはじめ。以来10年以上にわたり継続的な人工知能の研究開発とビジネス化・資金力強化を行い、2015年同社を創業。代表取締役社長CEOとして経営・技術戦略を指揮し、事業成長を牽引している。「画像認識と自然言語の組合せ機械学習による文字認識技術」や「情報を匿名暗号化して送信する技術」、「画像処理を用いた暗号化技術」など多数の技術特許を発明。




**Fellow**  
**胡 為明**

中国出身。組み込み系・Webアプリケーションや認証系ミドルウェアなど、幅広い開発プロジェクトに携わった経験を持つ。2019年4月に当社入社後、AIエッジコンピュータやノーコードAI開発・運用プラットフォームをサービス化し、ゼロからの事業開拓及び事業拡大に従事。技術経営修士（MOT）取得。2022年4月当社執行役員CTO就任。2025年4月当社Fellow就任。分散計算技術、Agent技術、暗号化技術に関する特許を発明。




**Tech Lead**  
**Charles Melby-Thompson**


アメリカ出身。日本やドイツなどで物理学者としてヒモ理論や量子重力について研究した経験を持つ。2020年6月にAI inside へ入社後、物理学者としての知見を活かし、データ分析などの数学的研究・実践をベースとした深層学習モデルやAIを活躍するシステムの構築をリードする。




**村山 善透**



**望月 雅也**



**趙 晨光**



**CHU Ruimin**

# 研究開発チーム「XResearch」



## ▼組織概要

CEO渡久地とFellow胡が陣頭指揮を執り、生成AI・LLMの研究開発と社会実装を推進する専門チーム。独自のLLMを開発するとともに、23年6月のチーム創設から、複数の生成AIプロジェクトの技術検証に取り組んでいる。

## ▼特許技術

Deep Learning による文字認識技術 / AIの配信技術 / 匿名暗号化技術 / データ圧縮転移技術 / UI等に関する特許 / コンテナ仮想化技術 / 分散処理システム技術 / ワークフロー技術

## ▼主な研究成果

23年6月

[140億パラメータの日本語LLM「PolySphere-1」を開発](#)

[「PolySphere-1」が2,259万トークンのプロンプトに返答成功](#)

23年10月

[「PolySphere-1」を活用した新プロダクト、AIエージェント「Heylix」を提供開始](#)

23年11月

[七十七銀行の生成AI導入プロジェクトを「Heylix」で支援](#)

24年1月

[AI-OCRサービス「DX Suite」に生成AIを実装](#)

24年4月

[損保ジャパンの火災保険における業務効率化を「Heylix」で支援](#)

24年8月

[日本語のドキュメント処理に特化した473億パラメータのLLM「PolySphere-2」を開発](#)

25年6月

[「PolySphere-3」にメジャーアップデートーデータ構造化の精度において世界最高性能を達成](#)

# 社会貢献性の高い先進的な研究事例(医療分野)



## AI inside、京都府立医科大学と共同研究で 指定難病の「眼表面希少疾患」の予後予測AIを開発

### 課題

眼表面希少疾患であるStevens-Johnson症候群および中毒性表皮壊死融解症は、人口100万人当たり2.5人ほどの希少疾患のため、知見豊富な医師が限られ、十分な医療サービスを提供することが難しかった。

### ソリューション

患者の前眼部写真から進行を予測するAIを開発。今回検証に参加した医師グループでは、知見の深い医師と同程度の予測パフォーマンスを発揮することを実証できた。

専門医学雑誌「Allergy」※1で公開

「AMED」の難治性疾患実用化研究事業※2に採択

※1 2024年4月25日 [Allergy「Clinical applicability of AI-based prognosis prediction for a rare ocular surface disease」](#)

※2 ゲノム・データ基盤プロジェクト/診療に直結するエビデンス創出研究分野/希少難治性疾患の診療に直結するエビデンス創出研究（エビデンス創出）